

이윤선

AI Inference/Serving Engineer

yoons7829@gmail.com | ckc5800.github.io | github.com/ckc5800

M.S. Computer Science, Inha University (2021.08) · B.S. Computer Science, Hannam University (2018.02)

PROFESSIONAL SUMMARY

모델을 서비스로 만드는 구간에서 병목을 계측으로 찾아 지연과 처리량을 바꾸는 일을 합니다.

- 엔진 처리량 **4.5배** (0.68 → 3.09 rps) — FP8 양자화·executor 백엔드 교체·vLLM 마이그레이션
- TTS 첫 응답 **절반 단축** (1,943 → 985ms) — 전체 합성 후 전송을 문장 단위 즉시 전송으로 전환
- **20여 개 모델**이 도는 Kubernetes 클러스터의 관측 스택 **5종** 단독 구축 (3인 인프라 팀)
- 논문 7편 · 특허 2건 (제1저자 · 제1발명자), 한국국방기술학회 우수논문상

TECHNICAL SKILLS

Serving · Inference: vLLM, Triton Inference Server, ONNX Runtime, FP8 Quantization, CUDA

Backend · Infra: FastAPI, gRPC, WebSocket, Asyncio, Redis, Kubernetes, Docker, ArgoCD, Jenkins, Harbor, NFS

Observability: Prometheus, Grafana, AlertManager, Loki, ELK | **AI/ML:** PyTorch, Hugging Face, Whisper, LangGraph | **Languages:** Python (Expert), TypeScript, SQL

MiCo AI (구 에이아이세스) | AI Engineer · Serving | Apr 2025 – Present

Qwen3-TTS 플랫폼 구축 (2026.03 ~ 현재) | PM 및 풀스택 단독 개발 (Backend / Frontend / Infrastructure)

▶ 배경: 상담센터를 타깃으로 제안할 자사 TTS 솔루션을 신규 구축 — 기존 시스템 교체가 아니라 제품을 처음부터 만드는 과제. 모델 선정(1.7B→0.6B)부터 아키텍처 설계·최적화·배포·운영까지 전 구간 단독 수행, 고객사 PoC·시연 진행

- ▶ 시스템 아키텍처: vLLM 추론 엔진 위에 FastAPI 게이트웨이, Redis 캐싱·분산락, React 관리자 대시보드까지 전 구간 설계·개발. 긴 텍스트를 문장 단위로 나눠 첫 문장부터 WebSocket으로 내보내는 스트리밍 구조로 첫 소리까지의 대기를 단축
- ▶ 기능 확장: 참조 음성 5초로 화자 목소리를 복제하는 기능 구현. OpenAI TTS API 호환 인터페이스로 외부 서비스가 코드 수정 없이 연동
- ▶ 운영 고도화: vLLM(GPU)·Supertonic(CPU) 듀얼 엔진 — 장애 시 Circuit Breaker가 CPU 엔진으로 자동 fallback. 무중단 롤링 재배포 체계와 온보딩 가이드·운영 런북·장애복구 절차·성능 명세를 갖춰 운영 이관 가능 수준으로 정비
- ▶ 성과 (KPI) — Throughput: 0.68 → 1.41 rps (FP8·executor 최적화) → 3.09 rps (vLLM 0.24 마이그레이션, +80%). 이후 고도화로 TTFB p50 70ms, 8.6 rps (2026.07 실측)
- ✓ 모델 경량화(1.7B→0.6B) 후 엔진 재튜닝: burst p95 TTFB 0.5초(동시 15)·1초(동시 30), 동시 스트림 수용 한계 36 실측
- ✓ 32개 언어 지원 단일 플랫폼 (vLLM 10 + Supertonic 22) | ITN 정규화 정확도 50.1% → 70.9% (검증셋 기준)
- ▶ 핵심 엔지니어링 7건 — 전면 백색소음 장애(SSE JSON이 PCM으로 재생), CPU 스파이크(ReDoS 가드가 치환마다 재생성), 팝 노이즈(PCM 홀수 바이트 정렬), 스토리지 누수, 세션 보안, ITN 토큰라이저, WAV 헤더 단일

화 — 원인 규명 과정은 포트폴리오에 정리

- ▶ 오픈소스 기여 (vllm-project/vllm-omni) — 운영 중 호스트 메모리 선형 증가를 abort된 요청의 sender 상태 미회수로 규명. 부하·할당자·캐시가 다른 4개 구성에서 증가율은 13배 차이 나지만 abort당 36~56 KB로 일정한 불변량을 근거로 원인 확정, 최소 패치 A/B로 257 → 60 MiB/h(77% 감소) 검증. 이슈 #6352로 리포트한 뒤 같은 원인의 기존 PR #4349에 프로덕션 검증 데이터 제공 — 작성자·리뷰어가 근거로 인용 (머지 대기)
- ▶ 기술: Python 3.12, FastAPI, WebSocket, vLLM-Omni, Redis, React 18, TypeScript, CUDA, FP8 Quantization

TTS 스트리밍 API 리팩토링 (2025.09 ~ 2025.10)

- 기존 TTS(ZipVoice 기반)의 TTFB가 텍스트 길이에 비례해 늘어나 실시간 상담에 부적합했고, 기존 담당자에게 인계받아 스트리밍 API 리팩토링을 담당 (기여도 100%)
- 브라우저 decodeAudioData()가 두 번째 청크부터 실패하는 고객 이슈를 추적 — 엔진이 첫 청크에만 RIFF WAV 헤더를 포함하는 것이 원인. 모든 SSE 청크에 독립 WAV 헤더를 부착해 해결
- 전체 합성 완료 후 분할 전송하던 기존 구조의 TTFB 한계를 확인하고, gRPC server streaming 기반 실시간 엔드포인트를 신설 — 문장 단위 합성 즉시 전송. API v2 표준화(v1 하위 호환)·Swagger 문서 정비·비교 데모 페이지 제공
- 성과: 같은 텍스트 완주 비교에서 TTFB 1,943ms → 985ms (절반 이하로 단축, 데모 페이지 콘솔 로그) | Python, FastAPI, Streaming API, ZipVoice

STT 배포 (2025.07 ~ 2025.09)

- AIG 상담센터의 대량 상담 전화를 실시간 처리해야 했으나 동시 채널이 부족했음 — 팀 내 배포·서빙 담당으로 Faster Whisper 기반 STT 엔진을 맡아 파일 배치와 실시간 스트리밍을 모두 지원하도록 정비
- Triton Python 백엔드로 파일 기반(화자 분리 결합)·실시간 스트리밍 두 추론 모델을 구성하고 HTTP·gRPC 제공. 화자 구간을 추론 파라미터로 넘겨 화자별 전사를 생성. 계층 모듈화·컨테이너 자동 재시작으로 안정성 보강 — 고객사 AIG 요구사항 4건 해결

Speaker Diarization (2025.04 ~ 2025.07)

- 상담 품질 분석을 위해 상담사·고객 발화를 구분해야 했음 — Pyannote 사전 학습 모델을 공개 화자 분리 데이터로 파인튜닝해 DER로 검증하고, STT와 연동해 화자가 구분된 전사 파이프라인을 구성 (Pyannote, PyTorch, Audio Processing)

인피닉 (INFINIQ) | AI Engineer · MLOps Engineer | Aug 2022 – Apr 2025

Kubernetes 기반 AI 인프라 (2024.03 ~ 2025.04)

- AI 서비스 20여 개를 수동 배포해 배포 1회에 수 시간이 걸리던 상황 — 인프라 엔지니어 3인이 온프레미스에 사내 최초 Kubernetes 플랫폼을 구축하고, 그중 관측성 전 계층(지표·경보·로그)과 스토리지를 맡아 설계·구축·운영
- 스토리지 담당 — NFS 기반 PV/PVC로 모델 가중치·데이터 영속 볼륨을 구성해, 파드가 재시작돼도 모델을 다시 받지 않도록 정비. 클러스터 네트워크(MetalLB LoadBalancer, Nginx Ingress 라우팅)는 팀에서 구성
- 서비스를 Docker로 컨테이너화해 Deployment·StatefulSet으로 올리고, GitLab → Jenkins·Argo Workflow → Harbor → ArgoCD GitOps 파이프라인으로 20개 이상 ML 모델을 자동 배포 (팀 성과)
- 관측 스택 5종을 단독 구축 — Prometheus 지표와 Grafana 대시보드로 20여 개 모델 상태를 한 화면에 모으고, AlertManager 경보로 사람이 발견하기 전에 장애를 알리도록 전환. 온프레미스라 Elasticsearch·Loki를 클러스터에 직접 설치·운영

NLP-based Text Summarization System (2024.01 ~ 2024.07)

- 대화 요약은 BART, 문서 요약은 T5로 나눠 개발. 한국어 대화-요약 쌍 수집·전처리부터 임베딩 모델 선정까지 학습 파이프라인을 직접 구축하고, 사전 학습 표현을 훼손하지 않는 R3F 정규화로 파인튜닝
- ROUGE와 사내 인원 휴먼 평가를 품질 지표로 사용. 사내 메신저에 실제 적용해 긴 공지를 한 줄로 줄이고 업무 대화를 2초대에 요약 (BART, T5, Hugging Face, PyTorch)

Research — Generative Model · 3D Segmentation (2022.08 ~ 2023.12)

- 국방 도메인은 보안 제약으로 학습 데이터 확보가 어려워, Latent Diffusion으로 합성 데이터를 생성하고 실제 모델 학습에 투입해 데이터 부족을 보완할 수 있음을 검증 — 제1저자 논문 2편, 한국국방기술학회 우수논문상 (2023.11)
- 자율주행 3D 인식을 위해 LiDAR·카메라 센서 퓨전 기반 Trans-Unet을 연구 — 한국자동차공학회 제1저자 논문 2편, 제1발명자 특허 2건 등록 (Latent Diffusion, GAN, Trans-Unet, PyTorch)

이든티앤에스 (EDEN T&S) | AI Engineer | Apr 2022 – Aug 2022

- OCR 데이터 자동 생성 툴 — 수동 주석이 병목이던 학습 데이터 생성을, 이미지 로딩·라벨링·저장을 갖춘 어노테이션 툴을 단독 개발해 자동화. 인식 성능 개선으로 프로젝트 성공 성과금 수령 (PyQt, Tesseract, ViT)

큐헷지 (QUHEDGE) | Intern | Sep 2020 – Sep 2021

- 금융 데이터 크롤링·정제·검증·저장까지 자동화 파이프라인을 구축해 수작업 수집을 대체 (Python, Pandas, SQL)

KISTI | Part-time | Oct 2017 – Jan 2018

- 한국어 고어(古語) 데이터 정제 및 전처리 작업 수행

PERSONAL PROJECTS

LLM 시스템 4종 | Jul 2026 – 진행 중 | github.com/ckc5800

- **rag-agent**
- **portfolio-mcp** — 포트폴리오 조회용 MCP 서버·클라이언트 양쪽 구현 (FastMCP, 의존성 2개)
- **pdm-agent** — 센서 이상탐지 + LLM 진단 파이프라인. NASA C-MAPSS 검증 — 고장 전 경보 94/100대, RUL 오차(MAE) 12.9사이클(30사이클 전 기준)
- **llm-bench** — 추론 벤치마크 CLI. Ollama 직렬화 병목 진단·재측정 — TTFT p50 12.4초→0.93초
- **공통**

CERTIFICATIONS & LANGUAGE

Linux Master (2016), Data Analytics Semi-Professional (2021) | English: OPIc IM1

PUBLICATIONS & PATENTS

- 제1저자 논문 7편 — 한국국방기술학회 우수논문상(2023), 한국자동차공학회 2편, 한국항공우주학회 (2023), 스마트미디어학회(2021), ACM(2018), 한국정보기술학회(2018)
- 제1발명자 특허 2건 — 센서 퓨전 기반 시맨틱 세그멘테이션·3차원 해석 방법 (등록 10-2538225 / 10-2538231)