

이윤선

6년차 AI 엔지니어

yoon7829@gmail.com | ckc5800.github.io | github.com/ckc5800 | taepseon.tistory.com

PROFESSIONAL SUMMARY

AI Engineer | MLOps Specialist

연구에서 시작해 인프라를 거쳐 서비스로 넘어온 6년차 AI 엔지니어입니다.

석사와 첫 직장들에서 논문 7편과 특허 2건을 쓰며 모델을 연구했고, 인피닉에서는 사내 첫 Kubernetes를 도입해 20여 개 모델의 배포 체계를 만들었습니다.

지금은 TTS 서비스를 설계부터 운영까지 맡아 첫 응답 시간을 2.3초에서 0.33초로 줄였습니다.

최근에는 RAG와 Multi-Agent 시스템을 만들며 LLM 시스템 엔지니어링으로 영역을 넓히는 중입니다.

MiCo AI (구 에이아이세스)

Manager | Apr 2025 – Present

TTS 프로젝트 (2025.09 ~ 현재)

PM 및 풀스택 개발 (Backend/Frontend/Infrastructure)

▶ 배경: 고객 상담 센터에 실시간 음성 합성이 필요했으나, 기존 시스템은 응답까지 2.3초가 걸리고 동시 처리도 12채널이 한계였음

▶ 시스템 아키텍처

vLLM 추론 엔진 위에 FastAPI 게이트웨이, Redis 캐싱과 분산락, React 관리자 대시보드까지 서비스 전 구간을 설계하고 구축. 긴 텍스트를 문장 단위로 나눠 첫 문장부터 WebSocket으로 스트리밍하는 구조로 체감 지연을 최소화.

▶ 기능 확장

참조 음성 5초만으로 화자 목소리를 복제하는 기능을 구현. OpenAI TTS API와 호환되는 인터페이스를 제공해 외부 서비스가 코드 수정 없이 연동되도록 지원.

▶ 성과 (KPI)

- ✓ TTFB: 2292ms → 334ms (85% 단축, 6.85배 개선)
- ✓ 동시 처리 채널: 12 → 24개 (2배 확대)
- ✓ Throughput: 0.68 → 1.41 rps (2배), 최적화 후 ~1.7 rps (2.5배 향상)
- ✓ 단건 지연시간 15% 감소 | RTF 0.1 이하 | CER(문자 오류율) 3~5%
- ✓ 32개 언어 지원 단일 플랫폼 | ITN 정규화 정확도 50.1% → 70.9%

▶ 핵심 엔지니어링 (5가지 문제 해결)

- ① 스트리밍 팝 노이즈: 홀수 바이트로 끊겨 오는 PCM 청크를 잔여 버퍼로 정렬해 잡음을 제거
- ② 스토리지 누수: 보이스 삭제 시 파생된 해시 캐시 파일까지 추적해 지우는 정리 로직으로 디스크 누수를 차단

- ③ 세션 보안: 비밀번호 변경 시점과 토큰 발급 시점을 대조해, 탈취된 토큰으로 웹소켓을 여는 우회를 차단
- ④ ITN 정규화: URL과 이메일을 자연스러운 한국어 발음으로 읽어 주는 정규식 토크나이즈를 직접 개발
- ⑤ CPU 병목: 요청마다 새로 생성되던 스레드풀을 걷어내 텍스트 처리 병목을 해소

▶ 기술 스택

Python 3.12, FastAPI, WebSocket, vLLM-Omni, Redis (Pub/Sub, Distributed Lock, TTL Cache), React 18, TypeScript, CUDA Optimization, FP8 Quantization

STT 배포 (2025.07 ~ 2025.09)

- 배경: AIG 상담센터의 대량 상담 전화를 실시간으로 처리해야 했으나 기존 시스템은 동시 채널이 부족했음
- 팀 내 배포·서빙 담당으로 WhisperX 기반 STT 엔진의 성능 개선과 운영 고도화를 수행
- 기술: Triton Inference Server, Streaming ASR Pipeline, Docker
- Triton 기반으로 추론 환경을 최적화해 동시 처리 채널을 늘리고, AIG 요구사항 4건을 해결

Speaker Diarization (2025.04 ~ 2025.07)

- 배경: 상담 품질을 분석하려면 상담사와 고객의 발화부터 구분해야 했음
- Pyannote 사전 학습 모델을 한국어 상담 데이터로 파인튜닝하고, 그 결과를 STT와 연동
- 기술: Pyannote, PyTorch, Audio Processing

인피닉 (INFINIIC)

AI Engineer/MLOps Engineer Aug 2022 – Apr 2025

Kubernetes 기반 AI 인프라 (2024.03 ~ 2025.04)

- 배경: 20개가 넘는 AI 서비스를 수동으로 배포하느라 배포 한 번에 수 시간이 걸렸음
- 사내 최초로 Kubernetes를 도입해 VM 수동 배포를 컨테이너 기반 자동 배포 체계로 전환
- MetalLB 로드밸런서와 Nginx Ingress로 서비스 노출 구조를 잡고, NFS 기반 PV/PVC로 영속 스토리지를 구성
- 기술: Kubernetes, Docker, Helm, GitLab CI/CD, Jenkins, ArgoCD, Prometheus/Grafana/Loki/ELK
- GitLab에서 Jenkins와 Harbor 레지스트리를 거쳐 ArgoCD로 배포되는 CI/CD 파이프라인을 구축해 20개 이상의 ML 모델 운영 환경을 마련
- Prometheus와 Grafana로 모니터링을, Loki와 ELK로 로그 수집을 구축하고 클러스터 장애 대응과 리소스 관리까지 담당

NLP-based Text Summarization System (2024.01 ~ 2024.07)

- 배경: 회의록과 업무 문서는 계속 쌓이는데 요약은 전부 수작업이었음
- BART 대화 요약과 T5 문서 요약 모델을 사내 데이터로 학습하고 성능을 개선
- 기술: BART, T5, Hugging Face, PyTorch
- 사내 자체 개발 메신저에 요약 기능을 붙여 회의록과 문서 요약에 실제 적용

Generative Model Research (2023.01 ~ 2023.12)

- 배경: 국방 도메인은 보안 제약 때문에 학습 데이터를 구하기 어려워, 생성 모델로 데이터를 만드는 쪽을 연구
- Latent Diffusion으로 합성 데이터를 생성하고 실제 모델 학습에 적용해 유효성을 검증
- 기술: Latent Diffusion, GAN, PyTorch
- 제1저자 논문 2편을 게재하고 국방기술학회에서 우수논문상을 수상 (2023.11)

3D Semantic Segmentation Research (2022.08 ~ 2022.12)

- 배경: 자율주행 인식에는 거리·높이 같은 3D 정보가 필요해, LiDAR와 카메라를 결합하는 센서 퓨전을 연구
- 한국자동차공학회에 제1저자 논문 2편을 게재하고, 제1발명자로 특허 2건을 등록
- 기술: Trans-Unet, LiDAR + Camera Sensor Fusion, PyTorch

이든티앤에스 (EDEN T&S)

AI Engineer Apr 2022 – Aug 2022

OCR Dataset Auto-Generation Tool

- 배경: OCR 학습 데이터를 대량으로 만들어야 했지만 수동 주석 작업이 병목이었음
- 이미지 로딩부터 라벨링, 저장까지 갖춘 어노테이션 툴을 혼자 설계하고 개발
- 기술: PyQt, Tesseract OCR, ViT-based Table Detection, RNN Text Extraction
- 학습 데이터 생성을 자동화하고 문서 인식 성능을 개선해, 프로젝트 성공 성과금을 받음

큐헷지 (QUHEDGE)

Intern | Sep 2020 – Sep 2021

금융 데이터 수집 및 전처리 파이프라인

- 배경: 여러 소스에 흩어진 금융 데이터를 손으로 모아 쓰고 있었음
- 금융 데이터를 크롤링하고 정제부터 검증, 저장까지 이어지는 자동화 파이프라인을 구축
- 기술: Python, Pandas, NumPy, SQL

한국어 고어 데이터 전처리

- 한국어 고어(古語) 데이터 정제 및 전처리 작업 수행

TECHNICAL SKILLS

Languages: Python (Expert), TypeScript, Bash, SQL

AI/ML: PyTorch, Hugging Face, vLLM, ONNX Runtime, Whisper

Model Serving: vLLM, Triton Inference Server, ONNX Runtime

Backend: FastAPI, gRPC, WebSocket, REST APIs, Asyncio

DevOps: Kubernetes, Docker, GitLab CI, Jenkins, ArgoCD, Harbor, Nginx

Data & Storage: Redis, PostgreSQL, MongoDB, S3, NFS

Monitoring: Prometheus, Grafana, Loki, ELK Stack, AlertManager

EDUCATION & CREDENTIALS

M.S. Computer Science | Inha University (2021.08)

B.S. Computer Science | Hannam University (2018.02)

Certifications: Linux Master (2016), Data Analytics Semi-Professional (2021)

Language: English (Intermediate, OPIc IM1)

PUBLICATIONS & PATENTS

Publications (First Author):

- 국방 데이터 확보를 위한 생성모델 Latent Diffusion 실험 | 국방기술학회 (2023) 우수논문상
- GAN을 활용한 데이터 생성 연구 동향 | 한국항공우주학회 (2023)
- 센서 퓨전 기반의 Trans-Unet을 활용한 2차원 시맨틱 세그멘테이션의 3차원적 해석 | 한국자동차 공학회 (2023)
- 자율 주행 도메인의 3차원 시맨틱 세그멘테이션을 위한 센서 퓨전 기반의 Trans-Unet | 한국자동차 공학회 (2022)
- 비정형, 정형 데이터의 이미지 학습을 활용한 시장예측 | 스마트미디어학회 (2021)
- Trend of Malware Detection Using Deep Learning | ACM International Conference (2018)
- Deep Learning을 활용한 악성코드 탐지 방법 동향 분석 | 한국정보기술학회 (2018)

Patents (First Inventor):

- Sensor Fusion-based Semantic Segmentation Method | Reg. No. 1025382250000
- 3D Interpretation Method for Semantic Segmentation | Reg. No. 1025382310000

Awards: Outstanding Paper Award – Korea Defense Technology Society (Nov 2023)