

이윤선

AI Inference/Serving Engineer

yoons7829@gmail.com | ckc5800.github.io | github.com/ckc5800 | taepseon.tistory.com

PROFESSIONAL SUMMARY

AI Inference/Serving Engineer | MLOps

연구에서 시작해 인프라를 거쳐 모델 추론 서빙으로 넘어온 6년차 AI 엔지니어입니다.

석사와 경력 초반 연구원 시절에 논문 7편과 특허 2건을 쓰며 모델을 연구했고, 인피닉에서는 사내 첫 Kubernetes를 도입해 20여 개 모델의 배포 체계를 만들었습니다.

지금은 AI 모델 추론 서빙을 맡아 — 기존 TTS 스트리밍 API의 첫 응답을 2.3초에서 0.33초로 줄였고, GPU/CPU 듀얼 엔진 서빙 플랫폼을 단독 설계·구축해 엔진 처리량을 4.5배(0.68→3.09rps) 끌어올렸습니다.

최근에는 RAG와 Multi-Agent 시스템을 만들며 LLM 시스템 엔지니어링으로 영역을 넓히는 중입니다.

MiCo AI (구 에이아이세스)

Manager | Apr 2025 – Present

Qwen3-TTS 플랫폼 구축 (2026.03 ~ 현재)

PM 및 풀스택 단독 개발 (Backend/Frontend/Infrastructure)

▶ 배경: 상담 센터용 음성 합성 모델의 추론 서빙 플랫폼을 단독 재구축 — 모델 선정(Qwen3-TTS 1.7B→0.6B)부터 vLLM(GPU)·Supertonic(CPU) 듀얼 엔진 서빙 아키텍처 설계, latency·throughput 최적화, 백엔드·프론트엔드, 배포·운영까지 전 구간 수행

▶ 시스템 아키텍처

Qwen3-TTS 기반 신규 플랫폼을 단독으로 구축 — vLLM 추론 엔진 위에 FastAPI 게이트웨이, Redis 캐싱과 분산락, React 관리자 대시보드까지 서비스 전 구간을 설계하고 개발. 긴 텍스트를 문장 단위로 나눠 전체 합성이 끝나기 전에 첫 문장부터 WebSocket으로 내보내는 스트리밍 구조로 사용자가 첫 소리를 듣기까지의 대기 시간을 줄임.

▶ 기능 확장

참조 음성 5초만으로 화자 목소리를 복제하는 기능을 구현. OpenAI TTS API와 호환되는 인터페이스를 제공해 외부 서비스가 코드 수정 없이 연동되도록 지원.

▶ 운영 고도화

vLLM(GPU)과 Supertonic(CPU) 듀얼 엔진 구성 — 장애 시 Circuit Breaker가 CPU 엔진으로 자동 폴백. 무중단 롤링 재배포 체계를 만들고, 온보딩 가이드·운영 런북·장애복구 절차·성능 명세까지 문서화해 운영 이관이 가능한 수준으로 정비.

▶ 성과 (KPI)

✓ Throughput: 0.68 → 1.41 rps (FP8·executor 최적화) → 3.09 rps (vLLM 0.24 마이그레이션, +80%)

✓ 32개 언어 지원 단일 플랫폼 (vLLM 10개 + Supertonic 22개) | ITN 정규화 정확도 50.1% → 70.9% (검증셋 기준)

✓ 이후 고도화(vLLM 마이그레이션·FP8): TTFB p50 70ms, 처리량 8.6 rps — 콜센터 활성 400명 규모 여유 (2026.07 실측)

✓ 모델 경량화 전환(1.7B→0.6B) 후 엔진 재튜닝: burst p95 TTFB 0.5초(동시 15)·1초(동시 30), 동시

스트림 수용 한계 36 실측 (2026.07 말)

▶ 핵심 엔지니어링 (7가지 문제 해결)

1. **스트리밍 팝 노이즈**: 재생 중 간헐적으로 '탁' 잡음이 나는 문제를 추적해, PCM 청크가 홀수 바이트로 끊겨 와 샘플 정렬이 깨지는 것을 원인으로 확인. 잔여 바이트를 다음 청크에 이어 붙이는 버퍼로 잡음을 제거
2. **스토리지 누수**: 보이스를 지워도 디스크 사용량이 계속 늘어나는 문제에서 파생 해시 캐시 파일이 남는 구조를 찾아내고, 파생 파일까지 추적해 지우는 정리 로직으로 누수를 차단
3. **세션 보안**: 비밀번호를 바꿔도 이미 발급된 토큰으로 웹소켓이 열리는 허점을 발견하고, 토큰 발급 시점과 비밀번호 변경 시점을 대조해 변경 이전 토큰을 전부 무효화
4. **ITN 정규화**: URL과 이메일이 섞인 문장을 자연스러운 한국어 발음으로 읽어 주는 정규식 토큰나 이저를 직접 개발해 낭독 품질을 개선
5. **CPU 스파이크(ReDoS 가드 오버헤드)**: 정규식 치환의 ReDoS 방어용 ThreadPoolExecutor 가드가 치환마다 새로 생성되어 다수 합성 시 CPU 스파이크를 유발 — 가드를 철거하고 네이티브 re.sub 동기 호출로 교체해 핫 패스 병목을 제거
6. **전면 백색소음 장애**: vLLM 0.24 전환 직후 모든 합성이 백색소음으로 나오는 문제를 추적해, 엔진의 SSE(JSON) 응답이 그대로 PCM으로 재생된 것이 원인임을 확인하고 응답 포맷을 오디오로 강제해 해결
7. **스트리밍 WAV 헤더 정리**: 엔진이 문장마다 RIFF 헤더를 붙여 보내 클라이언트 디코딩이 어긋나는 문제를, 헤더를 건너내고 세션 전체에 스트리밍 헤더를 한 번만 내보내는 구조로 정리해 해결

▶ 오픈소스 기여 (vLLM-Omni)

abort된 요청의 sender 상태 미회수를 호스트 메모리 선형 증가의 원인으로 규명 — 설정 4종에서 ~45 KB/abort로 일정함을 근거로 인과를 좁히고, 검증 패치로 257 → 60 MiB/h(77% 감소)를 확인. 이슈 #6352 리포트, 동일 원인 PR #4349에 프로덕션 검증 데이터 제공(작성자·리뷰어 인용, 머지 대기).

▶ 기술 스택

Python 3.12, FastAPI, WebSocket, vLLM-Omni, Redis (Pub/Sub, Distributed Lock, TTL Cache), React 18, TypeScript, CUDA Optimization, FP8 Quantization

TTS 스트리밍 API 리팩토링 (2025.09 ~ 2025.10)

- 배경: 기존 TTS(ZipVoice 기반)의 응답 지연(TTFB 2.3초)이 심각해 실시간 상담에 부적합했음
- 기존 담당자에게 인수인계 받아 스트리밍 API 리팩토링을 담당 (기여도 100%)
- 브라우저 decodeAudioData()가 두 번째 청크부터 실패하는 고객 이슈를 추적 — 엔진이 첫 청크에만 RIFF WAV 헤더를 포함하는 것이 원인. 모든 SSE 청크에 독립 WAV 헤더를 부착해 해결
- 전체 합성 완료 후 분할 전송하던 기존 구조의 TTFB 한계를 확인하고, gRPC server streaming 기반 실시간 엔드포인트를 신설 — 문장 단위 합성 즉시 전송. API v2 표준화(v1 하위 호환)·Swagger 문서 정비·비교 데모 페이지 제공
- 성과: TTFB 2292ms → 334ms (85.4% 단축, 6.85배 개선 — 측정 로그 기록)
- 기술: Python, FastAPI, Streaming API, ZipVoice

STT 배포 (2025.07 ~ 2025.09)

- 배경: AIG 상담센터의 대량 상담 전화를 실시간으로 처리해야 했으나 기존 시스템은 동시 채널이 부족했음

- 팀 내 배포·서빙 담당으로 Faster Whisper 기반 STT 엔진을 맡아, 파일 배치 처리와 실시간 스트리밍을 모두 지원하도록 운영 구조를 정비
- Triton Python 백엔드로 파일 기반(화자 분리 결합)과 실시간 스트리밍 두 추론 모델을 구성하고, HTTP와 gRPC 인터페이스를 모두 제공
- 화자 분리 결과를 STT에 결합해 화자별 전사를 생성 — 화자 구간을 추론 파라미터(clip timestamps)로 전달해 화자마다 정확한 전사를 얻는 구조를 구현
- 전처리·후처리·서비스 계층으로 코드를 모듈화하고, 로그 로테이션·아카이빙 체계와 Docker 구성 정비, 컨테이너 자동 재시작 정책으로 안정성을 보강
- 사내 회의록 기능에도 STT를 탑재 — Whisper 계열 모델별 성능을 조사해 최적 파라미터를 찾고, 파일 기반과 스트리밍 기반 처리를 모두 구현
- 기술: Triton Inference Server(Python Backend), Faster Whisper, Streaming ASR, gRPC/HTTP, Docker
- Triton 기반 추론 환경을 구성·개선하고, 고객사 AIG의 요구사항 4건을 해결

Speaker Diarization (2025.04 ~ 2025.07)

- 배경: 상담 품질을 분석하려면 상담사와 고객의 발화부터 구분해야 했음
- Pyannote 사전 학습 모델을 공개 화자분할 데이터로 파인튜닝해 DER로 검증하고, STT와 연동해 상담사와 고객이 구분된 전사 결과가 나오는 파이프라인을 구성
- 기술: Pyannote, PyTorch, Audio Processing

인피닉 (INFINIC)

AI Engineer/MLOps Engineer Aug 2022 – Apr 2025

Kubernetes 기반 AI 인프라 (2024.03 ~ 2025.04)

- 배경: 20개가 넘는 AI 서비스를 수동으로 배포하느라 배포 한 번에 수 시간이 걸렸음
- 사내 최초 Kubernetes 도입 프로젝트를 맡아, 기존 ML 서비스 운영 환경 분석부터 온프레미스 클러스터 아키텍처 설계, 배포, 운영까지 전 과정을 수행
- 서비스들을 Docker로 컨테이너화하고 Kubernetes Deployment와 StatefulSet으로 올려, VM 수동 배포를 컨테이너 기반 자동 배포 체계로 전환
- 온프레미스에는 클라우드식 로드밸런서가 없어 MetalLB로 LoadBalancer를 직접 구성하고, Nginx Ingress Controller로 외부 요청 라우팅과 서비스 노출 구조를 설계. 영속 데이터는 NFS 기반 PV/PVC로 구성
- 기술: Kubernetes, Docker, Helm, GitLab CI/CD, Jenkins, Argo Workflow, ArgoCD, Harbor, MetalLB, Nginx Ingress, NFS(PV/PVC), Prometheus/Grafana/AlertManager, Loki/ELK
- GitLab에 소스가 올라오면 Jenkins와 Argo Workflow가 이미지를 빌드해 Harbor 레지스트리에 올리고, ArgoCD가 클러스터에 배포하는 CI/CD 파이프라인을 구축해 20개 이상의 ML 모델을 자동 배포
- Prometheus와 Grafana로 서비스·클러스터 모니터링을, AlertManager로 경보를 구축. 로그는 클러스터에 Elasticsearch(ELK 스택)와 Loki를 직접 설치해 수집·조회 환경을 만들고, 이후 클러스터 장애 대응과 리소스 관리까지 운영을 담당

NLP-based Text Summarization System (2024.01 ~ 2024.07)

- 배경: 휴가나 부재 후 복귀한 직원이 단체방에 쌓인 업무 대화를 따라잡는 데 오랜 시간이 걸린다는 문제에서 출발, 사내 메신저에 넣을 요약 모델을 개발

- 대화 요약은 BART, 문서 요약은 T5로 나눠 개발. 한국어 대화-요약 쌍 데이터 수집과 전처리, 임베딩 모델 선정까지 학습 파이프라인을 직접 구축
- 파인튜닝에는 사전 학습 표현을 훼손하지 않는 R3F 정규화 기법을 적용하고, ROUGE 점수와 사내 인원 휴먼 평가를 품질 지표로 사용
- 기술: BART, T5, R3F Fine-tuning, Hugging Face, PyTorch
- 사내 메신저에 요약 기능을 붙여 실제 적용. 긴 사내 공지를 한 줄로 줄이고, 실제 업무 대화를 2초대에 요약하는 결과까지 확인
- STT 결과 텍스트를 활용한 자연어 처리 기능 개발과 모델 적용용 데이터 전처리·평가 환경 구축도 함께 수행

Generative Model Research (2023.01 ~ 2023.12)

- 배경: 국방 도메인은 보안 제약 때문에 학습 데이터를 구하기 어려워, 생성 모델로 데이터를 만드는 쪽을 연구
- Latent Diffusion으로 합성 데이터를 생성하고 실제 모델 학습에 투입해, 부족한 학습 데이터를 보완할 수 있음을 검증
- 기술: Latent Diffusion, GAN, PyTorch
- 제1저자 논문 2편을 게재하고 국방기술학회에서 우수논문상을 수상 (2023.11)

3D Semantic Segmentation Research (2022.08 ~ 2022.12)

- 배경: 자율주행 인식에는 거리·높이 같은 3D 정보가 필요해, LiDAR와 카메라를 결합하는 센서 퓨전을 연구
- 한국자동차공학회에 제1저자 논문 2편을 게재하고, 제1발명자로 특허 2건을 등록
- 기술: Trans-Unet, LiDAR + Camera Sensor Fusion, PyTorch

이든티앤에스 (EDEN T&S)

AI Engineer Apr 2022 – Aug 2022

OCR Dataset Auto-Generation Tool

- 배경: OCR 학습 데이터를 대량으로 만들어야 했지만 수동 주석 작업이 병목이었음
- 이미지 로딩부터 라벨링, 저장까지 갖춘 어노테이션 툴을 혼자 설계하고 개발
- 기술: PyQt, Tesseract OCR, ViT-based Table Detection, RNN Text Extraction
- 학습 데이터 생성을 자동화하고 문서 인식 성능을 개선해, 프로젝트 성공 성과금을 받음

큐헷지 (QUHEDGE)

Intern | Sep 2020 – Sep 2021

금융 데이터 수집 및 전처리 파이프라인

- 배경: 여러 소스에 흩어진 금융 데이터를 손으로 모아 쓰고 있었음
- 크롤링으로 데이터를 모으고 정제, 검증, 저장까지 이어지는 자동화 파이프라인을 구축해 수작업 수집을 대체
- 기술: Python, Pandas, NumPy, SQL

알바 | Oct 2017 – Jan 2018

한국어 고어 데이터 전처리

- 한국어 고어(古語) 데이터 정제 및 전처리 작업 수행

PERSONAL PROJECTS

LLM 시스템 4종 | Jul 2026 – 진행 중 | github.com/ckc5800

- **rag-agent** — LangGraph Corrective-RAG + 하이브리드 검색(FAISS·BM25 RRF). 51문항 유형별 평가셋으로 검색/생성 분리 측정, 채점기 결함을 스스로 검출해 6%p 보정
- **portfolio-mcp** — 포트폴리오 조회용 MCP 서버·클라이언트 양쪽 구현 (FastMCP, 의존성 2개)
- **pdm-agent** — 센서 이상탐지 + LLM 진단 파이프라인. NASA C-MAPSS 검증 — 고장 전 경보 94/100대, RUL 오차(MAE) 12.9사이클(30사이클 전 기준)
- **llm-bench** — 추론 벤치마크 CLI. Ollama 직렬화 병목 진단·재측정 — TTFT p50 12.4초→0.93초

TECHNICAL SKILLS

Languages: Python (Expert), TypeScript, Bash, SQL
AI/ML: PyTorch, Hugging Face, vLLM, ONNX Runtime, Whisper
Model Serving: vLLM, Triton Inference Server, ONNX Runtime
Backend: FastAPI, gRPC, WebSocket, REST APIs, Asyncio
DevOps: Kubernetes, Docker, GitLab CI, Jenkins, ArgoCD, Harbor, Nginx
Data & Storage: Redis, PostgreSQL, MongoDB, S3, NFS
Monitoring: Prometheus, Grafana, Loki, ELK Stack, AlertManager

EDUCATION & CREDENTIALS

M.S. Computer Science | Inha University (2021.08)
B.S. Computer Science | Hannam University (2018.02)
Certifications: Linux Master (2016), Data Analytics Semi-Professional (2021)
Language: English (Intermediate, OPIc IM1)

PUBLICATIONS & PATENTS

Publications (First Author):

- 국방 데이터 확보를 위한 생성모델 Latent Diffusion 실험 | 국방기술학회 (2023) 우수논문상
- GAN을 활용한 데이터 생성 연구 동향 | 한국항공우주학회 (2023)
- 센서 퓨전 기반의 Trans-Unet을 활용한 2차원 시맨틱 세그멘테이션의 3차원적 해석 | 한국자동차 공학회 (2023)
- 자율 주행 도메인의 3차원 시맨틱 세그멘테이션을 위한 센서 퓨전 기반의 Trans-Unet | 한국자동차 공학회 (2022)
- 비정형, 정형 데이터의 이미지 학습을 활용한 시장예측 | 스마트미디어학회 (2021)
- Trend of Malware Detection Using Deep Learning | ACM International Conference (2018)
- Deep Learning을 활용한 악성코드 탐지 방법 동향 분석 | 한국정보기술학회 (2018)

Patents (First Inventor):

- Sensor Fusion-based Semantic Segmentation Method | Reg. No. 1025382250000
- 3D Interpretation Method for Semantic Segmentation | Reg. No. 1025382310000

Awards: Outstanding Paper Award – Korea Defense Technology Society (Nov 2023)