

이윤선

AI Inference/Serving Engineer

yoons7829@gmail.com | ckc5800.github.io | github.com/ckc5800

M.S. Computer Science, Inha University (2021.08) · B.S. Computer Science, Hannam University (2018.02)

PROFESSIONAL SUMMARY

모델을 서비스로 올리는 단계에서 병목을 찾아 지연과 처리량을 개선하는 일을 합니다.

- 엔진 처리량 **4.2배** (0.73 → 3.09 rps) — FP8 양자화·vLLM 0.24 마이그레이션(Code2Wav CUDA-graph 배치)
- TTS 첫 응답 **49% 단축** (1,943 → 985ms) — 전체 합성 후 전송을 문장 단위 즉시 전송으로 전환
- **20여 개 모델**이 운영되는 Kubernetes 클러스터의 관측 스택 **5종** 단독 구축 (3인 인프라 팀)
- 사내 메신저 요약 기능 **전사 배포** (전 직원 약 300명) · 고객사 **상담센터 STT** 배포·운영
- 논문 7편 · 특허 등록 2건 (제1저자 · 제1발명자), 한국국방기술학회 우수논문상

TECHNICAL SKILLS

Serving · Inference: vLLM, Triton Inference Server, ONNX Runtime, FP8 Quantization, CUDA

Backend · Infra: FastAPI, gRPC, WebSocket, asyncio, Redis, Kubernetes, Docker, ArgoCD, Jenkins, Harbor, NFS

Observability: Prometheus, Grafana, AlertManager, Loki, ELK | **AI/ML:** PyTorch, Hugging Face, Whisper, LangGraph | **Languages:** Python, TypeScript, SQL

Certifications · Language: Linux Master Level 2 (2016.03), ADsP 데이터분석 준전문가 (2021.02) | English: OPIc IM1 (2021.10)

MiCo AI (구 에이아이세스) | AI Engineer · Serving | Apr 2025 – Present

Qwen3-TTS 플랫폼 구축 (2026.03 ~ 현재) | PM 겸 풀스택 단독 개발 (Backend·Frontend·Infra)

- 배경: 상담센터를 타깃으로 제안할 자사 TTS 솔루션을 신규 구축 — 기존 시스템 교체가 아니라 제품을 처음부터 만드는 과제. 모델 선정(1.7B → 0.6B)부터 아키텍처 설계·최적화·배포·운영까지 전 구간 단독 수행, 고객사 PoC·시연 진행
- 시스템 아키텍처: vLLM 추론 엔진 위에 FastAPI 게이트웨이, Redis 캐싱·분산락, React 관리자 대시보드까지 전 구간 설계·개발. 긴 텍스트를 문장 단위로 나눠 첫 문장부터 WebSocket으로 내보내는 스트리밍 구조로 첫 소리까지의 대기를 단축
- 기능 확장: 참조 음성 5초로 화자 목소리를 복제하는 기능 구현. OpenAI TTS API 호환 인터페이스로 외부 서비스가 코드 수정 없이 연동되도록 구성
- 운영 고도화: vLLM(GPU)·Supertonic(CPU) 듀얼 엔진 — 장애 시 Circuit Breaker가 CPU 엔진으로 자동 폴백. 무중단 롤링 재배포 체계와 온보딩 가이드·운영 런북·장애복구 절차·성능 명세를 갖춰 다른 담당자가 이어받을 수 있도록 정리
- 성과 (KPI) — Throughput: 최대 안정치 0.73 → 3.09 rps (4.2배). “1.7 rps가 천장”이라던 사내 결론을 버전×executor 2×전수 벤치로 반증 (1.7 → 3.09 rps, +80%)
 - 부하 테스트 3층 설계(스모크 → 순간 폭주 동시 4~256 → Poisson 도착 지속 부하) — 256건이 같은 순간 도착하는 폭주에도 실패 0, 지속 부하 TTFB p50 70ms(p95 219ms)·최대 8.7 rps (2026.07.20). 모델 경량화(1.7B → 0.6B) 후 재튜닝으로 burst p95 TTFB 0.5초(동시 15)·1초(동시 30), 동시 스트림 수용 한계 36
 - 32개 언어 지원 단일 플랫폼 (vLLM 10 + Supertonic 22) | ITN 정규화 정확도 50.1% → 70.9% (검증셋 기준)
- 핵심 엔지니어링 7건 — 전면 백색소음 장애(SSE JSON이 PCM으로 재생), CPU 스파이크(ReDoS 가드가 치환마다 재생성), 팝 노이즈(PCM 홀수 바이트 정렬), 스토리지 누수, 세션 보안, ITN 정규화, WAV 헤더 단일화 — 원인 규명 과정은 포트폴리오에 정리

- 메모리 누수 전수 조사 (vLLM-Omni 엔진) — 43시간 통런에서 발견한 호스트 메모리 선형 증가를 원인 6건(abort 송신측 상태, KV 블록 리스트, SHM 키 장부, jemalloc 미연결, 취소 요청 장부, torch 문자열 unbox)으로 규명해 모두 수정. 230~258 → +0.03 MiB/h, 운영 서버 70시간 343만 건 실패 0·재시작 0, 부하 종료 시 1,025 MiB 반납으로 누수 없음 확정
- 주 누수는 부하·할당자·캐시가 다른 4개 구성에서 증가율이 13배 달라도 abort당 36~56 KB로 일정한 불변량으로 특정(257 → 60 MiB/h). 잔여의 89%는 jemalloc 힙 프로파일 표집 보정으로 torch stable ABI 헤더까지 추적해 우회 패치. 이슈 #6352 리포트, 같은 원인의 기존 PR #4349에 검증 데이터 제공 — 작성자·리뷰어가 근거로 인용 (2026.09 기준 머지 대기)

TTS 스트리밍 API 리팩토링 (2025.09 ~ 2025.10)

- 기존 TTS(ZipVoice 기반)의 TTFB가 텍스트 길이에 비례해 늘어나 실시간 상담에 부적합. 전임 담당자에게 인계받아 스트리밍 API 리팩토링 전담 (기여도 100%)
- 브라우저 decodeAudioData()가 두 번째 청크부터 실패한다는 사내 사용 부서(API 호출측)의 제보를 추적 — 엔진이 첫 청크에만 RIFF WAV 헤더를 포함하는 것이 원인. 모든 SSE 청크에 독립 WAV 헤더를 부착해 해결
- 전체 합성 완료 후 분할 전송하던 기존 구조의 TTFB 한계를 확인하고, gRPC server streaming 기반 실시간 엔드포인트를 신설 — 문장 단위 합성 즉시 전송. API v2 표준화(v1 하위 호환)·Swagger 문서 정비·비교 데모 페이지 제공
- 성과: 같은 텍스트 완주 비교에서 TTFB 1,943ms → 985ms (49% 단축, 데모 페이지 콘솔 로그) | Python, FastAPI, Streaming API, ZipVoice

TTS 운영 · 품질 관리 (2025.10 ~ 2026.02)

- 기존 TTS 서비스의 운영과 품질을 맡아 합성 결과 QA, TTS 학습 데이터 정제, ZipVoice 모델 학습, 사내 운영 테스트를 수행

STT 배포 (2025.07 ~ 2025.09)

- 대형 보험사 상담센터의 대량 상담 전화를 실시간 처리해야 했으나 동시 채널이 부족했음 — 팀 내 배포·서빙 담당으로 Faster Whisper 기반 STT 엔진의 배포·운영과 구조 개선을 맡음
- 팀이 구성한 Triton 기반 파일·스트리밍 두 추론 모델(HTTP·gRPC)을 배포·운영. 전처리·후처리·서비스 계층을 모듈화해 두 경로의 공통 로직을 통합하고, 로그·Docker 구조와 컨테이너 자동 재시작 정책으로 안정성 보강

화자 분리(Speaker Diarization) 검토 (2025.04 ~ 2025.07)

- 자사 메신저 제품의 영상통화 회의록·전사에 화자 구분이 필요해 Pyannote 사전 학습 모델을 평가하고 데이터를 모아 파인튜닝 시도
- 사전 학습 모델 대비 DER 개선이 없어 미채택 — 판정 근거를 남기고 종료 (Pyannote, PyTorch)

인피닉 (INFINIQ) | AI Engineer · MLOps Engineer | Aug 2022 – Apr 2025

Kubernetes 기반 AI 인프라 (2024.08 ~ 2025.04)

- AI 서비스 20여 개를 수동 배포해 1회에 수 시간이 걸리던 상황 — 인프라 엔지니어 3인이 온프레미스에 사내 최초 Kubernetes 플랫폼을 구축하고, 그중 관측성 전 계층(지표·경보·로그)과 스토리지를 맡아 설계·구축·운영
- 스토리지 담당 — NFS 기반 PV/PVC로 모델 가중치·데이터 영속 볼륨을 구성해, 파드가 재시작돼도 모델을 다시 받지 않도록 정비. 클러스터 네트워크(MetalLB LoadBalancer, Nginx Ingress 라우팅)는 팀에서 구성
- 서비스를 Docker로 컨테이너화해 Deployment·StatefulSet으로 올리고, GitLab → Jenkins·Argo Workflow → Harbor → ArgoCD GitOps 파이프라인으로 20여 개 ML 모델을 자동 배포 (팀 성과)
- 관측 스택 5종을 단독 구축 — Prometheus 지표와 Grafana 대시보드로 20여 개 모델 상태를 한 화면에 모으고, AlertManager 경보로 사람이 발견하기 전에 장애를 알리도록 전환. 온프레미스라 Elasticsearch, Loki를 클러스터에 직접 설치·운영

NLP 문서·대화 요약 시스템 (2024.01 ~ 2024.07)

- 대화 요약은 BART, 문서 요약은 T5로 나눠 개발. 대화-요약 쌍 데이터 수집과 ROUGE·사내 휴먼 평가를 평가 계획으로 설계
- 사내 메신저(전 직원 약 300명)에 실제 적용해 긴 공지를 한 줄로 줄이고 업무 대화를 2초대에 요약 (BART, T5, Hugging Face, PyTorch)

국방 · 자율주행 비전 연구 (2022.08 ~ 2023.12)

- Latent Diffusion 합성 데이터 (2023.09 ~ 2023.12) — 보안 제약으로 학습 데이터 확보가 어려운 국방 도메인에서 Latent Diffusion으로 전차 이미지 생성 실험 — 웹 수집 전차 이미지 7,586장으로 새 이미지를 만들어 실제 데이터와 상당 부분 유사함을 확인(대체 수준은 아님) — 한국국방기술학회 우수논문상 (2023.11)
- 전차 탐지 모델 (2023.01 ~ 2023.08) — 국방 도메인 이미지에서 전차를 자동 탐지하는 모델 개발
- 3D 시맨틱 세그멘테이션 (2022.08 ~ 2022.12) — LiDAR·카메라 센서 퓨전 Trans-Unet 설계 — 2D MIoU 31.94%(단일 모달의 약 2배). 제1저자 논문 2편(한국자동차공학회), 제1발명자 특허 등록 2건

이든티앤에스 (EDEN T&S) | AI Engineer | Apr 2022 – Aug 2022

- OCR 데이터 자동 생성 툴 — 수동 주석이 병목이던 학습 데이터 생성을, 이미지 로딩·라벨링·저장을 갖춘 어노테이션 툴을 단독 개발해 자동화. 인식 성능 개선으로 프로젝트 성공 성과금 수령 (PyQt, Tesseract, ViT)

큐헷지 (QUHEDGE) | Contract | Sep 2020 – Sep 2021

- 금융 데이터 수집·전처리 파이프라인 구축 (Python)

KISTI | Part-time | Oct 2017 – Jan 2018

- 한국어 고어(古語) 데이터 정제 및 전처리 작업 수행

PERSONAL PROJECTS

개인 프로젝트 (주요 5종) | Jul 2026 – Present | github.com/ckc5800

- **rag-agent** — LangGraph Corrective-RAG + 하이브리드 검색(FAISS-BM25 RRF). 평가셋을 10 → 140문항으로 늘려가며 검색/생성 분리 측정, 코퍼스 15.6배 확장 후에도 튜닝값 유지 확인 (140문항 84.3%). 채점기 결함을 찾아내 6%p 보정
- **rag-preprocess-bench** — 한국어 PDF 전처리(파싱·청킹)가 RAG 검색 품질에 미치는 영향 실측. 문서 64개·1,450p·질문 300개 · page-level hit@10 73.0 → 85.3%(+12.3pp). 채택 4건보다 기각 10건이 많았고 사유를 전부 기록 (docling 전면 교체 -8pp·추출 3시간, RapidOCR 폴백이 한국어를 중국어 모델로 읽어 효과 0)
- **portfolio-mcp** — 포트폴리오 조회용 MCP 서버·클라이언트 양쪽 구현 (FastMCP, 의존성 2개)
- **pdm-agent** — 센서 이상탐지 + LLM 진단 파이프라인. NASA C-MAPSS 4개 셋에서 자명한 대조군과 비교 — 경보 유효율 93.6~98.0%(오탐 0~0.9%), 공식 test 셋 RUL MAE 15.8~23.0사이클
- **llm-bench** — 추론 벤치마크 CLI. Ollama 직렬화 병목 진단·재측정 — TTFT p50 12.4초 → 0.93초

PUBLICATIONS & PATENTS

- 제1저자 논문 7편 — 한국국방기술학회 우수논문상 (2023), 한국자동차공학회 2편 (2022·2023), 한국항공우주학회 (2023), 스마트미디어학회 (2021), ACM (2018), 한국정보기술학회 (2018)
- 제1발명자 특허 등록 2건 (2023.05) — 센서 퓨전 기반 시맨틱 세그멘테이션 방법(1025382250000)·시맨틱 세그멘테이션의 3차원 해석 방법(1025382310000)